

Raport: Spersonalizowany system rekomendacji kinowych

Wstęp

Niniejszy raport dokumentuje proces tworzenia spersonalizowanego modułu systemu rekomendacji filmowych z wykorzystaniem modelu LLM.

Głównym celem projektu było przeprowadzenie procesu fine-tuningu dużego modelu językowego w taki sposób, aby potrafił on trafnie przewidzieć ocenę punktową, jaką konkretny użytkownik przyznałby danemu filmowi, bazując wyłącznie na jego krótkim opisie fabularnym.

W przeciwieństwie do tradycyjnych algorytmów rekomendacyjnych, które często faworyzują popularne produkcje i opierają się na masowych trendach, proponujemy system, który w założeniu pozwala na skuteczne rekomendowanie niszowych, mało znanych filmów, bazując wyłącznie na dopasowaniu ich tematyki do unikalnego gustu użytkownika.

Dane - źródło, opis, analiza

Źródło i opis danych

Dane wykorzystane w projekcie pochodzą z publicznego zbioru udostępnionego na platformie Kaggle: **"Letterboxd Movie Ratings Data"** (autor: samlearner). Zbiór ten składa się z trzech głównych tabel:

- `movie_data.csv` – Szczegółowe informacje o filmach (zawiera 285 963 unikalne tytuły).
- `ratings_export.csv` – Oceny wystawione przez użytkowników (ponad 11 milionów zgromadzonych ocen).
- `users_export.csv` – Profile użytkowników platformy Letterboxd (8 139 unikalnych recenzentów).

Cechy, parametry

Dane charakteryzują się wysokim stopniem złożoności i bogatą informacją o filmach i użytkownikach.

Najistotniejsze wykorzystane podczas analizy kolumny i parametry to:

- **Parametry filmów (`movie_data`):** Tytuł, popularność, czas trwania, rok produkcji, gatunek i z jakiego kraju pochodzi dany film. Bardzo ważna jest też średnia ocena z iloczynem liczby oddanych przy niej głosów. Średnia ocena

filmów wynosi 4.12 w skali do 10 (najwyżej oceniane rzadko mają czyste 10, przy czym mediana to 5.10).

- **Pomiary ocen (ratings_data):** Identyfikator użytkownika, identyfikator filmu, wartość wystawionej oceny (rating_val).
- **Dane o użytkownikach (users_data):** Unikalny username, wyświetlana nazwa, oraz ogólna zagregowana liczba recenzji (num_reviews).

Kolumny wykorzystane podczas fine-tuningu:

- **user_id** w tabeli **ratings_export** - zawierająca identyfikator użytkownika, który wystawił daną ocenę - użyty do wyodrębnienia ocen należących tylko do badanego użytkownika
- **movie_id** w tabelach **movie_data** i **ratings_export** – identyfikator filmu - użyty do odnalezienia opisów filmów, które ocenił badany użytkownik
- **overview** w tabeli **movie_data** - krótki opis filmu - użyty do treningu i analizy tekstu, na podstawie której model ma wystawić przewidywaną ocenę
- **rating_val** w tabeli **ratings_export** – ocena filmu wystawiona przez konkretnego użytkownika - użyta jako etykieta, którą ma przewidzieć model na podstawie opisu

Eksploracyjna Analiza Danych (EDA)

Pierwszy etap prac obejmował eksplorację zbioru danych (EDA) z wykorzystaniem środowiska Jupyter Notebook. Przeprowadzona analiza statystyczna oraz wygenerowane wykresy (plik analiza.ipynb) dostarczyły kluczowych informacji o strukturze danych:

- **Rozkład ocen:** Większość z nas z przeogromnego natłoku filmów wybiera po prostu te lepsze. Histogram ocen potwierdza to idealnie: większość ocen mieści się w przedziale 5-8 punktów. Znacznie rzadziej chcemy wystawiać niskie (np. ułamkowe) oceny słabym filmom.
- **Analiza krajów produkcji:** Stworzono zestawienie państw dominujących w kinematografii. Bezdyskusyjnym rynkiem dominującym są USA (ponad 73 tys. przypisanych tytułów), a kolejne to Wielka Brytania, Francja, Niemcy i Japonia.
- **Rozkład kinowych gatunków:** Użytkownicy najczęściej wybierają dramaty, a w drugiej kolejności – komedie. W top 5 znajdziemy również dokumenty, thrillery i horrory.
- **Ewolucja względem lat:** Platforma Letterboxd ma mocny przechył w stronę produkcji dwudziestego pierwszego wieku; wyraźna eksplozja tworzonych do bazy filmów następuje w postępie czasowym po 2000. roku.
- **Aktywność recenzentów:** W bazie zostały umieszczone dane najbardziej aktywnych użytkowników. Rekordzista wystawił ponad 17000 ocen, a średnia liczba ocen na osobę wynosi ponad 860.

Analiza i interpretacja pod kątem aplikacji rekomendującej

Preferencje użytkowników i rozkład ocen: Rozkład ocen pokazuje wyraźną koncentrację w przedziale 5–8. Użytkownicy rzadko wystawiają oceny skrajne, preferując wartości środkowe lub lekko pozytywne. Taka struktura danych może negatywnie wpłynąć na trening modelu – algorytm, dążąc do minimalizacji błędu, może nabrać tendencji do generowania najbezpieczniejszych, uśrednionych predykcji.

Znaczenie popularności filmów: Analiza wykazała, że filmy z dużą liczbą ocen (vote_count) to głównie popularne produkcje, często dobrze oceniane. Oznacza to, że popularność jest silnym sygnałem rekomendacyjnym, jednak nie powinna być jedynym kryterium – w przeciwnym razie mniej znane filmy będą pomijane.

Wybór modelu HuggingFace Transformers

Cel użycia LLM

Model przeanalizuje opis filmu i przewidzi, jaką ocenę w skali punktowej przyznałby mu dany użytkownik.

- **Input:** Tekstowy opis filmu w języku angielskim (kolumna “overview” w movie_data.csv - string)
- **Output:** Pojedyncza, ciągła wartość liczbowa (zmiennoprzecinkowa float), reprezentująca przewidywaną ocenę (np. 4.2) w skali od 0 do 10.

Ponieważ model opiera się na uczeniu nadzorowanym, podczas treningu zostanie mu przekazana również rzeczywista ocena użytkownika, jako wartość docelowa do nauki.

Wybrany model

Nazwa modelu: distilbert-base-uncased

Typ modelu: Oparty na enkoderze Transformer (Encoder-only).

Uzasadnienie wyboru

Zadaniem modelu jest przeczytanie, przeanalizowanie i zrozumienie opisu filmu, następnie na podstawie tego zrozumienia przypisanie mu przewidywanej oceny. Do takiego zadania pasuje model Encoder-only.

Architektura typu BERT analizuje tekst dwukierunkowo, co pozwala na zrozumienie szerszego kontekstu opisu. Jest to kluczowe do wyłapywania zniuansowanych motywów w opisie (np. specyficznego rodzaju humoru lub nastroju), które często pojawiają się w opisach filmów.

Dlaczego wersja distil?

Zastosowanie wersji DistilBERT jest optymalnym kompromisem. Model ten zachowuje niemal pełną zdolność rozumienia języka oryginalnego modelu BERT, zajmując przy tym mniej pamięci i działając szybciej.

Ocena jakości

Ponieważ zastosowano regresję, zamiast wskaźnika accuracy do oceny poprawności modelu wykorzystamy **wskaźnik MAE**, który wskaże, o ile średnio punktów oceny myli się model.

Oczekiwane dane wyjściowe

Postać wyniku: Pojedyncza liczba ułamkowa z przedziału 0-10.

Interpretacja: Dokładna, spersonalizowana prognoza oceny, jaką dany użytkownik przyznałby nowemu filmowi.

Rodzaj skali: Płynna (ciągła). Pozwala to systemowi na oddanie niuansów gustu - wskazuje, z jaką siłą film rezonuje z widzem, zamiast sztywno przypisywać go do pełnych kategorii ocen.

Fine-tuning modelu LLM - założenia, przebieg, wyniki

1. Przygotowanie danych wejściowych

Wybór użytkownika

Zgodnie z założeniami wyizolowaliśmy wycinek danych dla jednego, konkretnego użytkownika - shiftless. Wybraliśmy go ze względu na jego aktywność - 3721 unikalnych recenzji. Uznaliśmy, że jest to odpowiednia liczba danych, która nie obciąży zbytnio naszych zasobów sprzętowych, a jednocześnie zapewni modelowi wystarczającą próbę do nauki.

Wyodrębnienie potrzebnych danych

Z tabeli ocen wyselekcjonowaliśmy wyłącznie aktywność wybranego użytkownika, po czym połączyliśmy uzyskany zbiór z bazą filmów na podstawie unikalnego identyfikatora filmu (movie_id). Z połączanego zestawu wyodrębniono wyłącznie dwie kolumny niezbędne do dalszego treningu:

- **overview** (cecha wejściowa): tekstowy opis fabuły.
- **rating_val** (zmienna docelowa): ocena wystawiona przez użytkownika.

Czyszczenie danych

W trakcie filtrowania danych zadbaliliśmy również o ich wyczyszczenie, żeby ewentualne błędy nie wpłynęły negatywnie na wyniki. Z bazy filmów usunęliśmy ewentualne duplikaty oraz wiersze z brakującymi opisami filmów.

Przekonwertowaliśmy wartości ocen na format zmiennoprzecinkowy, a nazwę

kolumny zmieniliśmy na label, co jest standardowym wymaganiem bibliotek do uczenia maszynowego.

Podział na zbiory

Dane podzielono na zbiór uczący (80%) i testowy (20%), ustawiając stałe ziarno losowości (seed=42) w celu zapewnienia powtarzalności wyników.

Tokenizacja

Tokenizacja przekształca opisy filmów na tensory liczb (token IDs) zrozumiałe dla DistilBERT. Parametr **truncation=True** obcina sekwencje dłuższe niż 512 tokenów (limit modelu), **padding="max_length"** dopełnia wszystkie sekwencje do jednakowej długości - jest to prostsze, choć pamięciowo mniej efektywne niż dynamiczne dopełnianie.

2. Architektura modelu i konfiguracja treningu

Zadanie regresji

Ponieważ celem jest przewidywanie oceny w skali ciągłej, a nie przypisywanie tekstu do oddzielnych kategorii, podczas inicjalizacji modelu ustawiony został parametr `num_labels=1` odpowiadający za wygenerowanie przez model pojedynczej wartości liczbowej.

Metryka ewaluacyjna

Do pomiaru skuteczności modelu użyliśmy MAE (Mean Absolute Error - średni błąd bezwzględny). W czytelny sposób wskazuje ona, o ile średnio (w skali punktowej 0-10) predykcje algorytmu odchylają się od rzeczywistych ocen użytkownika.

Parametry treningu

Liczba epok (Epochs): 2 – przy większej liczbie epok zauważyliśmy, że występuje zjawisko przeuczenia

Współczynnik uczenia (Learning rate): $2e-5$ - zmieniliśmy domyślną wartość z $5e-5$ na bardziej odpowiednią dla fine-tuningu architektur opartych na Transformerach

Rozmiar paczki (Batch size): Ustawiliśmy zachowawczą wartość 4 zarówno dla fazy treningu, jak i ewaluacji. Taki rozmiar pozwala na stabilne trenowanie modelu przy uwzględnieniu ograniczeń pamięciowych sprzętu (w naszym przypadku 4 GB VRAM).

Optymalizacja obliczeń: Włączyliśmy obsługę arytmetyki półprecyzyjnej (FP16), aktywowanej w przypadku wykrycia kompatybilnej karty graficznej. Rozwiązanie to drastycznie przyspiesza proces nauki i redukuje zużycie pamięci VRAM.

3. Zasoby sprzętowe

Sprzęt wykorzystany do treningu: Trening przeprowadziliśmy na karcie graficznej NVIDIA GeForce RTX 3050 Laptop GPU (4 GB VRAM).

Środowisko: Zainstalowano niezbędne pakiety wspierające technologię CUDA, co umożliwiło przetwarzanie modelu na GPU.

Wydajność: Uruchomienie procesu na układzie graficznym zamiast na procesorze głównym pozwoliło na drastyczny wzrost wydajności - całkowity czas treningu modelu uległ skróceniu z ponad godziny do zaledwie około 3 minut.

4. Wyniki i ewaluacja

Proces treningowy, obejmujący dwie epoki, przebiegł stabilnie i zakończył się po zaledwie 3 minutach i 14 sekundach.

Zestawienie wyników prezentuje poniższa tabela:

Epoka	Strata trenowania (Training Loss)	Strata walidacji (Validation Loss)	Błąd bezwzględny (MAE)
1	4.046	1.468	0.939
2	1.614	1.391	0.901

Finalne MAE na zbiorze testowym: 0.9012

Pomiędzy pierwszą a drugą epoką nastąpił znaczący spadek straty trenowania przy jednoczesnym spadku straty walidacyjnej i błędu bezwzględnego. Świadczy to o tym, że model w trakcie tych dwóch epok nie wpadł jeszcze w pułapkę przeuczenia.

Ostateczna wartość wskaźnika MAE na poziomie 0.90 oznacza, że weryfikując opisy nowych filmów, model myli się w przewidywaniu gustu użytkownika średnio o niecały jeden punkt (w skali 0-10). Z technicznego punktu widzenia jest to obiecujący wynik.

Interpretując uzyskane wyniki, należy jednak wziąć pod uwagę rozkład ocen użytkownika shiftless. Istnieje prawdopodobieństwo, że tak dobry wynik błędu całkowitego wynika po części ze strategii modelu, który dążąc do minimalizacji straty, wyuczył się generowania bezpiecznych predykcji, rzadziej celując w trudne do przewidzenia oceny skrajne.

Przykładowe predykcje modelu:

Tekst: A group of astronauts embarks on a dangerous mission to save humanity ...

Przewidziana ocena: 5.31

Tekst: A romantic comedy about two strangers who fall in love during a weeken...

Przewidziana ocena: 6.86

Tekst: A dark psychological thriller about a detective hunting a serial kille...

Przewidziana ocena: 6.46

Wnioski:

1. **Wyniki modelu:** MAE ≈ 0.90 na zbiorze testowym po 2 epokach oznacza, że model myli się średnio o niecały 1 punkt na skali 0–10 - wynik obiecujący, biorąc pod uwagę, że model opiera się wyłącznie na opisach filmów.
2. **Ograniczenia:** Model jest dopasowany do gustu jednego użytkownika (shiftless) i nie generalizuje na innych. Opis fabuły (overview) nie zawsze odzwierciedla subiektywne preferencje - ten sam film może być oceniony na 3 lub 9 przez różnych widzów.
3. **Możliwe ulepszenia:**
 - a. Więcej epok treningu (3-5) z wczesnym zatrzymaniem (`load_best_model_at_end=True`)
 - b. Dodanie cech kontekstowych (gatunki, rok produkcji)
 - c. Przetestowanie większych modeli (BERT-base, RoBERTa)
 - d. Normalizacja etykiet do zakresu [0, 1] dla stabilniejszego treningu